

Atelier : Nettoyage des données

1 Présentation

L'objectif de cet atelier est de concevoir et de mettre en œuvre un workflow pour le traitement et le nettoyage d'un fichier Excel.

Nous disposons d'une base de données regroupant les informations des candidats inscrits à diverses formations proposées par notre établissement. Cette base est au format Excel, avec les colonnes suivantes :

- **Nom, Prénom**
- **Date de naissance**
- **CIN**
- **Téléphone**
- **Email**
- **Établissement**
- **Formation**
- **Lettre de motivation,**
- etc.

Le travail consiste à identifier et corriger toutes les anomalies présentes dans cette base (voir le cours pour les types d'anomalies).

2 Travail à faire :

Étape 1 : Détection manuelle des anomalies

1. **Identification des anomalies :**
 - Analysez chaque colonne pour détecter les anomalies telles que :
 - Erreurs syntaxiques
 - Formats incorrects
 - Valeurs aberrantes
 - Doublons
 - Valeurs nulles, etc.
 - **Propositions de corrections :**
 - Documentez les corrections nécessaires pour chaque anomalie détectée au niveau des colonnes.
 - Identifiez également les incohérences inter-colonnes et proposez les corrections associées.
2. **Création du workflow :**
 - Présentez un schéma détaillé du workflow de traitement.

Étape 2 : Implémentation des fonctions de traitement

1. Développez deux fonctions pour chaque type d'anomalie :
 - Une fonction pour **détecter** les anomalies.
 - Une fonction pour **corriger** ces anomalies.
2. Implémentez le workflow complet pour automatiser le nettoyage des données.

Étape 3 : Ajout de fonctionnalités de journalisation (log)

Ajoutez les fonctionnalités suivantes à votre script :

- **Statistiques globales :**
 - Nombre d'anomalies détectées par type.
 - Nombre d'anomalies corrigées par colonne.
 - Nombre de lignes corrigées.
- **Écriture d'un fichier log au format CSV** contenant les informations suivantes :
 - Date et heure de l'opération (jj/mm/aa, hh:mm:ss).
 - Type d'anomalie.
 - Numéro de ligne et de colonne concernés.
 - Valeur d'origine et valeur corrigée.

Étape 4 : Exécution finale

- Regroupez tout le code dans un seul script et exécutez-le sur le fichier Excel fourni.

4 Le rapport :

Le rapport doit inclure :

1. **Introduction** : Présentation du contexte de ce projet dans votre formation.
2. **Spécifications** : Description détaillée des fonctionnalités du script développé.
3. **Solution proposée** :
 - Explication des étapes de réalisation, accompagnée de captures d'écran de votre code.
 - Résultats obtenus après exécution du script.
4. **Conclusion** :
 - Votre avis sur le projet, l'efficacité des résultats obtenus et les améliorations possibles.

Remarque importante

L'utilisation d'un api du modèle de langage (LLM) dans votre code est autorisée pour détecter les erreurs grammaticales et syntaxiques dans vos données et votre code.