

Chapitre 1

Introduction à l'apprentissage automatique (ML)

L'**apprentissage automatique** (*machine learning*, ML) est un domaine de l'informatique dans lequel les données sont utilisées pour **prédire** ou **interpréter** des données futures. Il est étroitement lié aux domaines de la reconnaissance de formes, des statistiques informatiques et de l'intelligence artificielle. Les données peuvent être **historiques** ou **mises à jour en temps réel**. Le ML est important dans des domaines tels que la reconnaissance faciale, le filtrage de spams et d'autres domaines où il n'est pas possible, ou voir très difficile, d'écrire des algorithmes pour réaliser une tâche.

1.1 Un aperçu de l'apprentissage automatique

Le ML a été inventé en 1959 par Arthur Samuel (*Bell Labs*, IBM, Stanford) dans le cadre de la résolution de jeu de dames par machine. Le terme fait référence à des **programmes informatiques** qui **peuvent apprendre** à produire des comportements qui ne sont pas explicitement programmés par les concepteurs de ces programmes.

En bref, le ML est la **capacité d'apprendre ses propres connaissances à partir des données brutes**. Il s'agit donc essentiellement d'un **processus de décision dirigé par les données**.

La méthodologie du ML est différente de celle de la programmation classique. Dans la programmation classique, les programmeurs écrivent des programmes traitant des données spécifiques en entrée et fournissant des résultats souhaités en sortie après exécution par l'ordinateur.

La méthodologie du ML tente de prendre en compte les données et les sorties at-

8 CHAPITRE 1. INTRODUCTION À L'APPRENTISSAGE AUTOMATIQUE (ML)

tendus, le cas échéant, et utilise l'ordinateur pour créer le programme, également appelé **modèle**. Ce programme ou modèle peut ensuite être utilisé ultérieurement pour prendre les décisions nécessaires et donner les résultats attendus à partir de nouvelles données.

Les deux figures suivantes illustrent la différence entre le ML et la programmation traditionnelle au niveau de leurs méthodologies.




FIGURE 1.1 – Paradigme de la programmation classique.




FIGURE 1.2 – Paradigme du ML.

Voici une **définition formelle** donnée par Tom Mitchell qui essaie d'approcher le terme "apprentissage machine" :

■ *A computer program is said to learn from experience E with respect to some class of tasks T and performance measure P , if its performance at tasks in T , as measured by P , improves with experience E .*

D'après la définition précédente, le ML est un domaine qui consiste en des algorithmes d'apprentissage qui améliorent leurs performances P , lors de l'exécution d'une tâche T au fil du temps avec l'expérience E . La figure suivante illustre ces trois composants fondamentaux d'un algorithme de ML.




FIGURE 1.3 – Les trois composants fondamentaux d'un modèle de ML.

1.1.1 Tâches de ML

Il y a plusieurs types de tâches en ML. Parmi lesquelles, on peut citer à titre d'exemples :

- **Classification** : consiste à **attribuer une classe** à chaque échantillon. Un exemple simple serait de classer une image d'un animal : chien/chat/vache.
- **Régression** : implique généralement d'effectuer une **prédiction** de sorte que la sortie est une **valeur numérique réelle** au lieu d'une classe. Par exemple, la prévision des prix des logements compte tenu de la superficie, de l'étage, des salles de bains, des chambres et de la cuisine comme attributs d'entrée.
- **Détection d'anomalies** : consiste à trouver un comportement anormal ou inhabituel passant en revue des journaux d'événements, de transactions ou d'autres points de données. Un exemple typique de cette tâche est la recherche des attaques sur un réseau informatique.
- **Clustering** ou **regroupement** : consiste à regrouper des échantillons de données par l'apprentissage et l'observation des relations et des similarités entre les points de données eux-mêmes. Un exemple simple serait le regroupement de produits similaires.
- **Transcription** : consiste à convertir des données qui sont généralement continues et non structurées en éléments de données plus structurés et plus

discrets. Un exemple typique est la conversion de la parole en texte.

1.1.2 Expériences en ML

Tout algorithme d'apprentissage a généralement besoin de données pour apprendre au fil du temps et effectuer une tâche spécifique T . Le **processus de consommation** d'un **ensemble de données** (**dataset**) constitué d'échantillons ou de points de données par l'algorithme d'apprentissage pour **apprendre des modèles inhérents** est défini comme étant l'**expérience** E acquise par cet algorithme d'apprentissage.

L'**acquisition de l'expérience** par un algorithme d'apprentissage est souvent un **processus itératif**, appelé "**entraînement du modèle**". Les **ensembles de données** sont utilisés pour **entraîner** le système. Ces ensembles peuvent être collectés et édités manuellement ou automatiquement rassemblés par des logiciels spécifiques. Les systèmes de contrôle peuvent collecter des données à partir de **capteurs** (*sensors*) pendant le fonctionnement des systèmes et utiliser ces données pour identifier les paramètres ou entraîner le système.

Les **ensembles de données** peuvent être **très volumineux** (contexte du *big data*), et c'est l'explosion de l'infrastructure de stockage de données et des bases de données disponibles qui est en grande partie le moteur de la croissance des programmes de ML aujourd'hui.

1.1.3 Performances en ML

Étant donné un algorithme de ML qui est censé effectuer une tâche T , et qui acquiert de l'expérience E à partir d'un dataset sur une période de temps. Comment savoir si cet algorithme fonctionne correctement ? C'est là que la **performance** P du modèle entre en jeu.

La **performance** P est une **mesure quantitative** utilisée pour voir dans quelle mesure l'algorithme ou le modèle exécute la tâche T avec l'expérience E . Bien que les mesures de performance sont généralement standards et établies après des années de recherche, chaque métrique est calculée spécifiquement pour la tâche T que l'algorithme de ML essaie de résoudre à un moment donné.

Les mesures de performance typiques incluent l'**exactitude** (*accuracy*), la **précision**, le **rappel** (*recall*), le **score F1**, la **sensibilité** (*sensitivity*), la **spécificité**, le **taux d'erreur**, le **taux d'erreurs de classification** et bien d'autres.

Les **mesures de performance** sont généralement évaluées sur des **échantillons de données d'entraînement** (*training data*) utilisés par l'algorithme pour

acquérir de l'expérience E , ainsi que sur des **échantillons de données de validation** et de **test**.

1.2 Méthodes de ML

Le ML dispose de plusieurs algorithmes, techniques et méthodologies qui peuvent être utilisés pour créer des modèles afin de résoudre des problèmes du monde réel à partir des ensembles de données.

1.2.1 Apprentissage supervisé

Les techniques d'**apprentissage supervisé** incluent des algorithmes d'apprentissage qui prennent une collection de paires **données d'apprentissage/sorties associées** (appelées **étiquettes** ou **réponses**), pendant le processus d'apprentissage du modèle. L'objectif principal étant d'**apprendre une correspondance** entre les échantillons de données d'entrée x et leurs sorties correspondantes y sur la base de plusieurs instances de données d'apprentissage. Cette connaissance acquise peut ensuite être utilisée ultérieurement pour prédire une sortie y' pour un nouvel échantillon de données d'entrée x' .

La **classification** et la **régression** font parties des **algorithmes d'apprentissage supervisés**.

1.2.2 Apprentissage non supervisé

L'**apprentissage non supervisé** consiste davantage à essayer d'**extraire des informations significatives** à partir de données plutôt que d'essayer de prédire un résultat basé sur des données. Il y a plus d'incertitude dans les résultats de l'apprentissage non supervisé, mais nous pouvons aussi obtenir beaucoup d'informations à partir de ces modèles qui n'étaient auparavant pas disponibles dans les données brutes.

Les méthodes d'apprentissage non supervisé sont, par exemple, utilisées pour les tâches de **regroupement** (*clustering*), la **détection des anomalies**, et l'**extraction des règles d'association**.

1.2.3 Apprentissage semi-supervisé

Les méthodes d'**apprentissage semi-supervisé** se situent entre les méthodes d'apprentissage supervisé et non supervisé. Ces méthodes utilisent généralement un **grand nombre de données d'apprentissage non étiquetées** (formant le composant d'apprentissage non supervisé) et une **petite quantité de données**

pré-étiquetées et annotées (formant le composant d'apprentissage supervisé). Le petit ensemble de données étiquetées est utilisé pour interpréter les données non étiquetées.

Plusieurs techniques d'apprentissage semi-supervisé sont disponibles sous la forme de **méthodes génératives**, de **méthodes basées sur des graphes** et de **méthodes basées sur les heuristiques**.

1.2.4 Apprentissage par renforcement

L'**apprentissage par renforcement** concerne un **agent** que nous souhaitons entraîner sur une période de temps pour interagir avec un environnement spécifique et améliorer ses performances au regard du type d'actions qu'il effectue sur l'environnement. En général, l'agent commence par un ensemble de stratégies ou de politiques d'interaction avec l'environnement.

En observant l'environnement, l'agent entreprend une action particulière basée sur une règle ou une politique sur son observation de l'état actuel de l'environnement. Sur la base de l'action, l'agent obtient une **récompense**, qui peut être bénéfique ou préjudiciable sous la forme d'une pénalité. Il met à jour ses politiques et stratégies actuelles si nécessaire et ce processus itératif se poursuit jusqu'à ce qu'il en apprenne suffisamment sur son environnement pour obtenir les récompenses souhaitées.