

TD 1

Exercice 1 :

1. Montrer que l'application norme $x \mapsto \|x\|_p$ est convexe.
2. Pour toute fonction convexe $f : y \in \mathbb{R}^m \mapsto f(y)$, montrer que $g : x \in \mathbb{R}^d \mapsto f(Ax - b)$ est une fonction convexe avec $A \in \mathbb{R}^{n \times d}$ et $b \in \mathbb{R}^n$.
3. pour $i = 1, \dots, m$ soit $y_i \in \mathbb{R}$ et $a_i \in \mathbb{R}^d$, prouvez que la fonction de régression logistique $f(x) = \frac{1}{n} \sum_{i=1}^n \ln(1 + e^{-y_i \langle x, a_i \rangle})$ est convexe.
4. on dit qu'une fonction f est μ -fortement convexe si et seulement si

$$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle + \frac{\mu}{2} \|y - x\|_2^2, \quad \forall x, y \in \mathbb{R}^d$$

Montrer que f vérifie la condition de Polyak-Lojasiewicz :

$$\|\nabla f(x)\|_2^2 \geq 2\mu (f(x) - f(x^*)), \quad \forall x$$

5. Calculer la dérivées de la fonction quadratique $f(x) = \langle Ax, x \rangle - \langle b, x \rangle$ avec $x, b \in \mathbb{R}^n$ et $A \in \mathbb{R}^{n \times n}$.

Exercice 2 : La régression Ridge est peut-être l'exemple le plus simple d'un problème d'apprentissage automatique. Considérez la tâche d'apprentissage qui permet de trouver la relation entre un vecteur de caractéristiques $x \in \mathbb{R}^d$ et un vecteur d'observation $y \in \mathbb{R}$. De plus, vous disposez d'un ensemble d'observations étiquetées (x_i, y_i) pour $i = 1, \dots, n$. Nous désirons résoudre le problème :

$$w^* = \arg \min_w \frac{1}{n} \sum_{i=1}^n \frac{1}{2} (x_i^\top w - y_i)^2 + \frac{\lambda}{2} \|w\|_2^2,$$

avec $\lambda > 0$ en utilisant une méthode de descente à pas fixe.

1. Montrer que le problème s'écrit de la manière suivante $f(w) \stackrel{\text{def}}{=} \frac{1}{2n} \|X^\top w - y\|_2^2 + \frac{\lambda}{2} \|w\|_2^2$ en précisant la matrice A et le vecteur y .
2. Dédurre que la fonction f est convexe.
3. On considère le schéma de descente :

$$w^{t+1} = w^t - \alpha \nabla f(w^t)$$

avec $\alpha = \frac{1}{\sigma_{\max}(A)}$ et $A \stackrel{\text{def}}{=} \frac{1}{n} X X^\top + \lambda I$.

- (a) calculer le $\nabla f(w)$.

(b) Montrer que A est définie positive.

(c) Montrer que

$$\|w^{t+1} - w^*\|_2 \leq \left(1 - \frac{\sigma_{\min}(A)}{\sigma_{\max}(A)}\right) \|w^t - w^*\|_2$$

Exercice 3 :

Soit $A \in \mathcal{M}_n(\mathbb{R})$ une matrice symétrique définie positive. On pose

$$f : x \in \mathbb{R}^n \mapsto \frac{1}{2} \langle Ax, x \rangle - \langle b, x \rangle$$

et $r_k = \nabla f(x_k)$

1. Montrer que $d_k = -\nabla f(x_k)$ est une direction de descente. Montrer que $A d_k$ est également une direction de descente.

2. Rappeler l'algorithme du gradient à pas optimale.

3. Montrer que le pas de descente vaut $\alpha_k = \frac{\langle r_k, r_k \rangle}{\langle Ar_k, r_k \rangle}$ pour la méthode du gradient à pas optimale

Exercice 4 :

Soit $A \in \mathcal{M}_n(\mathbb{R})$ une matrice symétrique définie positive. Résoudre $Ax = b$ est équivalent à minimiser

$$f : x \in \mathbb{R}^n \mapsto \frac{1}{2} \langle Ax, x \rangle - \langle b, x \rangle$$

En effet, le minimum $\bar{x}$ de f (qui existe et qui est unique puisque f est strictement convexe et coercive) vérifie $\nabla f(\bar{x}) = 0$. Or $\nabla f(x) = Ax - b$. Une méthode de descente est une méthode itérative qui approche le minimum de f (et donc la solution de $Ax = b$) en construisant la suite $(x_k)_{k \in \mathbb{N}}$:

$$\begin{cases} x_0 \in \mathbb{R}^n \\ x_{k+1} = x_k + \alpha_k d_k \end{cases}$$

Dans ce qui précède, pour $k \in \mathbb{N}$,

- $\alpha_k > 0$ est le pas de la méthode,

- $d_k \in \mathbb{R}^n$ est une direction de descente, c'est-à-dire un vecteur de $\mathbb{R}^n$ tel que

$$\langle \nabla f(x_k), d_k \rangle \leq 0$$

Lorsque l'inégalité précédente est stricte, on parle de direction stricte de descente.

- On définira aussi le résidu r_k par $r_k = \nabla f(x_k) = Ax_k - b$.

1. Montrer que

$$d_k = -r_k + \frac{\langle Ar_k, d_{k-1} \rangle}{\langle Ad_{k-1}, d_{k-1} \rangle} d_{k-1},$$

est une direction de descente avec l'initialisation $d_0 = -r_0 = b - Ax_0$.

2. Trouver en fonction de r_k, d_k et A , l'expression du pas optimale :

$$\alpha_k = \underset{\alpha > 0}{\operatorname{argmin}} f(x_k + \alpha d_k)$$

3. Montrer que les résidus vérifient la relation de récurrence suivante :

$$r_{k+1} = r_k + \alpha_k A d_k, \forall k \geq 0$$

.